

短学期课程项目·立项报告

自动化求职工具

招聘职位数据可视化分析与个性化推荐系统

课程：Python 数据分析与可视化（短学期·32 学时）

小组：_____（5 人）

成员：_____ 学号：_____

日期：2026 年 9 月 1 日

摘要

针对招聘信息海量分散、求职筛选费时的痛点，本项目面向学生求职者，构建自动化求职工具。系统爬取招聘网站的大数据相关职位信息，经清洗标准化后存入数据库，从薪资、技能需求、企业画像等维度挖掘分析，结合用户简历画像，采用 TF-IDF 余弦相似度、随机森林回归、KMeans 聚类算法，给出个性化岗位推荐与求职报告，以 Streamlit Web 应用可视化展示全流程，帮助求职者高效了解行业待遇、定位合适岗位。

关键词：Python；数据爬取；数据分析；个性化推荐；Streamlit

目录

摘要.....	I
目录.....	II
1 项目背景.....	1
1.1 课程背景.....	1
1.2 问题与痛点.....	1
1.3 项目目标.....	1
2 同类产品分析.....	2
3 需求分析.....	4
3.1 用户角色与使用场景.....	4
3.2 功能需求.....	4
3.3 非功能需求.....	4
4 技术方案.....	5
4.1 技术路线.....	5
4.2 技术栈.....	6
4.3 数据库设计.....	7
4.4 算法设计.....	8
5 项目可行性分析.....	10
5.1 技术可行性.....	10
5.2 团队可行性.....	11
5.3 开发计划与里程碑.....	12
5.4 数据与风险应对.....	12
6 技术参考与参考资料.....	12
6.1 课程参考材料.....	12
6.2 项目参考资料.....	13

1 项目背景

1.1 课程背景

本课程为短学期《Python 数据分析与可视化》，共 32 学时，要求以 Python 及相关工具为技术栈，组队完成一个面向数据分析与可视化的软件开发项目。项目一般应为 Web 项目，包含数据爬取、清洗、分析与可视化，且至少包含三个不同类型的算法。本选题参照往届题目 3「招聘网站职位信息可视化分析与个性化推荐」，并将其升级为自动化求职工具，突出“自动化”特色。

1.2 问题与痛点

在线招聘平台每天发布大量职位信息，职位、薪资、技能与公司信息分散且口径不一；求职者手工筛选费时费力，难以横向比较不同岗位的待遇与要求，也缺少与自身画像匹配的个性化参考，容易错过合适岗位或高估自身竞争力。

1.3 项目目标

本项目构建自动化求职工具，形成「采集—清洗—分析—推荐—报告」闭环。功能目标：自动采集招聘职位数据、清洗标准化入库、开展薪资 / 技能需求 / 企业画像分析、基于简历画像做个性化推荐，并自动生成求职报告；技术目标：采用分层架构与可配置爬虫，实现至少四个可评估算法，全链路可视化，并以自动化测试保障代码质量。

2 同类产品分析

表 1 同类产品对比

产品	数据来源	推荐依据	可复现性与局限
BOSS 直聘 / 智联招聘	站内职位与用户行为数据	登录后的浏览、投递历史	依赖平台账号，算法不可见，无法离线复现
LinkedIn Job Match	站内简历与技能图谱	结构化简历画像匹配	面向海外数据，数据封闭，不支持自定义数据集

产品	数据来源	推荐依据	可复现性与局限
拉勾 / 猎聘推荐	单一平台职位	浏览历史与收藏	聚焦单平台，缺少薪资、技能等多维分析
本项目（自动化求职工具）	公开职位接口 / 样例数据	职位文本 TF-IDF 匹配 + 硬过滤	数据源可配置、算法可复现，面向校园求职场景

对比可见，主流产品均依赖平台封闭数据与行为日志，推荐依据不可见、难以复现。本项目以公开职位文本为基础，推荐过程完全可解释、可离线复现，并补充薪资分析、技能图谱与自动报告能力，更适合作为课程项目进行完整的数据采集、分析与展示。

3 需求分析

3.1 用户角色与使用场景

系统的主要用户为求职者（以应届生为主）与小组内部运维角色。求职者希望在求职前快速了解行业待遇与岗位要求，输入自身画像后获得匹配岗位与薪资预期，并定期收到新增岗位提醒；组长与成员需要一键运行完整数据流程，以便演示、验收与答辩。

3.2 功能需求

核心功能以用户故事描述如下：

1. 作为求职者，我能输入技能、城市、学历与期望薪资，系统返回 Top-N 匹配岗位与匹配度。
2. 作为求职者，我能按城市、学历、经验查看薪资分布，评估自身待遇水平。
3. 作为求职者，我能查看热门技能及组合关系，规划学习方向。
4. 作为求职者，我能获得新增岗位与匹配提醒（自动日报）。
5. 作为组长，我能一键运行「采集—清洗—分析—展示」全流程。
6. 作为评审，我能查看数据质量报告与清洗前后对比，验证数据可靠性。

3.3 非功能需求

- 性能：数据加载使用缓存，页面交互响应及时。
- 可靠性：真实站点抓取失败时自动降级为样例数据，保证演示链路不中断。
- 可维护性：分层模块化设计，单元测试覆盖关键函数，代码通过 `ruff` 规范检查。
- 合规：仅采集公开信息，限速并尊重站点规则，不代替用户自动投递简历。

4 技术方案

4.1 技术路线

系统采用五层架构：采集层通过可配置爬虫（关键词 × 城市 × 页码，BFS/DFS 调度，UA 池、限速与重试）获取职位数据；数据层完成薪资解析、去重与标准化，存入 SQLite / CSV；算法层实现个性化推荐、薪资预测、岗位聚类与技能图谱；展示层以 Streamlit 多页面应用呈现全部结果；自动化层负责定时爬取、自动日报与投递材料包生成。

开发流程采用 TDD：每个任务先编写 REQUIREMENTS.md 需求文档，测试先行，小步实现并持续验证；以 pytest 作为回归保障，以 ruff 作为代码质量门禁。




图 1 系统五层架构（数据流方向：左 → 右）

4.2 技术栈

表 2 技术栈

类别	工具 / 框架	用途
语言与 环境	Python 3.12 / venv	开发与运行环境
爬虫	requests / BeautifulSoup	职位数据采集与解析
数据 处理	pandas / jieba	清洗、标准化、技能提取
算法	scikit-learn	TF-IDF、随机森林、KMeans
可 视 化	matplotlib / wordcloud / networkx	图表、词云、共现网络
Web 应用	Streamlit	多页面交互界面
存 储	SQLite / CSV	数据持久化与共享
工 程 化	pytest / ruff / git	测试、规范检查、协作管理




图 2 分城市薪资分布箱线图（项目真实数据）

4.3 数据库设计

数据以 jobs 主表存储于 SQLite，清洗后字段如下；salary_min / salary_max / salary_avg 由薪资文本解析为数值（单位 K/月），“面议”岗位薪资为空、不参与预测训练；技能以逗号分隔字符串存储，分析时再解析为列表。

表 3 jobs 表字段设计

字段	类型	说明
title / city	str	职位名称 / 工作城市
education / experience	str	学历要求 / 经验要求（已标准化）
company / company_size / company_type	str	公司名称、规模、性质
salary_text	str	原始薪资文本
salary_min / salary_max / salary_avg	float	月薪区间与均值（K/月）
skills / skill_count	str / int	技能标签与数量
description	str	职位描述
publish_date / link	str	发布日期 / 职位链接

4.4 算法设计

表 4 算法设计

算法	原理	输入 → 输出	评估指 标
个性化推荐	TF-IDF + 余弦 相似度 + 硬过 滤	简历画像 + 职位文本 → Top- N 与匹 配度	Top-N 人工校 验
薪资预测	随机森 林回归	城市/ 学历/ 经验/ 规模/ 技能数 → 薪资 区间	MAE、 R ²

算法	原理	输入 → 输出	评估指 标
岗位聚类	KMeans	职位描述 向量 → 岗位簇 与画像	轮廓系 数
技能图谱	词频 + 共现统计	技能标签 → 词云 与共现网络	频次 / 共现权重

四个算法分属内容匹配、回归预测、无监督聚类与统计图分析四类，满足课程“至少包含三个不同类型算法”的要求；每个算法均提供可视化页面与可解释的评估指标，便于现场答辩。




图 3 薪资预测特征重要性 (随机森林回归)



图 4 职位技能词云 (项目真实数据)

5 项目可行性分析

5.1 技术可行性

团队成员具备《程序设计》《Python》《数据分析》等前置课程基础，课程推荐技术栈（pandas、scikit-learn、matplotlib、Streamlit）均已在本机验证：320 条样例数据全链路跑通，44 个自动化测试通过，Streamlit 四页面渲染无异常。真实招聘网站存在反爬风险，已实测并记录（接口存活但返回空结果），方案上通过限速、UA 池与多数据源规避，并在抓取失败时自动降级样例数据，保证演示不中断。

5.2 团队可行性

小组共 5 人，按采集层、数据层、算法层、可视化与自动化分工，模块间通过 CSV / SQLite 解耦，可并行开发；采用 git 提交记录、例会纪要与代码审查保障协同；答辩采用随机抽题，要求每位成员深度掌握自己负责的模块，并对 AI 生成的代码逐行理解。

表 5 团队分工

角色	负责模块	主要任务
组长	架构 / 进度 / 联调	总体设计、里程碑管理、答辩统筹
成员 A	采集层	站点配置、调度策略、反爬对策、解析器
成员 B	数据层	清洗流水线、数据字典、SQLite、质量报告
成员 C	算法层	推荐算法、薪资预测模型与评估
成员 D	可视化 / 自动化	Streamlit 页面、图表选型、自动报告

5.3 开发计划与里程碑

表 6 项目开发计划与里程碑

版本	时间节点	里程碑	交付物
V0.1 概念验证	Day1-2	M1 立项通过	可运行原型 + 立项报告
V0.5 中期可演示	Day3-4	M2 中期检查	全链路演示 + 中期报告
V1.0 项目验收	Day5-6	M3 验收答辩	完整功能 + 答辩材料

5.4 数据与风险应对

- 反爬风险：限速、UA 池、多站点切换；全部失败时自动降级内置样例数据（≥300 条）。
- 数据源改版：解析器与站点配置独立成模块，可快速替换解析规则。
- 时间紧张：遵循“链路优先、美化后置”，每天保持可运行版本。
- AI 生成代码不可控：强制逐行理解、加注释，并以测试兜底。

6 技术参考与参考资料

6.1 课程参考材料

1. Python 基础教程：<https://www.runoob.com/python/python-install.html>
2. Python 基础教程（W3School）：<https://www.w3school.com.cn/python>
3. requests 中文文档：<https://requests.readthedocs.io/projects/cn/zh-cn/latest/>
4. Python3 requests 教程：<https://www.runoob.com/python3/python-requests.html>
5. requests-html 中文文档：<https://wthahaha.github.io/requests-html-doc-cn/>
6. pandas 中文文档：<https://pandas.ac.cn/docs/index.html>
7. scikit-learn 中文文档：<https://scikit-learn.org.cn/>
8. matplotlib 官方文档：<https://www.matplotlib.net/>

9. Streamlit 官方文档: <https://streamlit.io/>

10. 《利用 Python 进行数据分析（原书第 3 版）》：

https://github.com/iamseancheney/python_for_data_analysis_2nd_chinese_version

6.2 项目参考资料

1. 项目 README（安装与使用说明）
2. docs/data_dictionary.md（数据字典）
3. docs/爬虫调研与反爬笔记.md（真实站点实测记录）
4. .requirements/ 需求文档（TDD 过程记录）